

Klasifikacija bioma unutar video igre na osnovu ekranskih snimaka korišćenjem neuronskih mreža

Veljko Jovanović

Fakultet tehničkih nauka, Univerzitet u Novom Sadu
Trg Dositeja Obradovića 6, Srbija
jovanovic.e212.2024@uns.ac.rs

Sažetak — Rad opisuje sistem za višeklasnu klasifikaciju slika koji iz slika napravljenih unutar Minecraft igre (RGB, 320x180 piksela) predviđa biom prikazan na slici. Skup podataka sadrži 22.169 slika u 41 klasi, sa izrazito nebalansiranim raspodelom (odnos najveće i najmanje klase je približno 3.000:1). Implementirana su dva modela: (i) referentna konvoluciona mreža sa tri konvoluciona sloja trenirana od nule i (ii) EfficientNet-B0 pretreniran na ImageNet skupu, sa novim klasifikacionim slojem. Poređene su dve konfiguracije obuke: v1 sa dvostrukim rebalansiranjem (težine unakrsne entropije i uzorak sa reponderisanjem istovremeno) i v2 sa jednostavnim, umerenim rebalansom (koren-inverzna frekvencija), zaglađivanjem oznaka i jačom augmentacijom. Na test skupu (3.326 slika) EfficientNet-B0 u v2 konfiguraciji postiže makro F1 od 0,70 i F1 w. od približno 0,80, dok referentna mreža postiže makro F1 od 0,37 (w. F1 0,62). Glavni empirijski zaključak jeste da konfiguracija gubitka i strategije uzorkovanja na ovoj raspodeli utiče bar koliko i sam izbor arhitekture.

Ključne reči — klasifikacija slika, konvolucione mreže, transfer učenja, EfficientNet, nebalansirane klase, Minecraft.

I. UVOD

Prepoznavanje tipa okruženja iz ekranskog snimka video-igre spaja klasične probleme prepoznavanja scena sa izraženom domenskom specifičnošću: gradivne jedinice sveta su blokovi karakterističnih tekstura, a prizori se u praksi generišu proceduralno, pa pokazuju visoku vizuelnu raznolikost unutar iste klase. Iako je zadatak akademski, isti oblik problema “klasifikacija scene iz snimka igre” direktno je primenljiv u zadacima snimanja igranja radi analize stila igranja (engl. *Gameplay*) i u automatizovanom testiranju.

Ulaz u sistem je RGB slika dimenzija 3 kanala, 180 piksela u visinu i 320 piksela u širinu. Izlaz je jedna od 41 klase bioma. Cilj je da model bude tačan i na klasama koje su količinski dominantne (plains, forest, mountains — više od 65 % svih uzoraka) i na klasama sa jednocifrenim brojem uzoraka u test skupu (npr. *snowy_taiga_mountains*, sa svega jednim uzorkom).

Doprinos rada je dvostruk. (1) Postavljena je ponovljiva eksperimentalna infrastruktura sa jednom, stratifikovanom podelom 70/15/15 koja se koristi u svim eksperimentima; obe konfiguracije modela su trenirane pod istom podelom i vrednovane istim skupom metrika. (2) Kroz uporedne v1 i v2 eksperimente pokazujemo da dvostruka rekalkibracija; težinska funkcija gubitka pomnožena reponderisanjem na nivou uzorka, na ovoj raspodeli klasa dovodi do kolapsa

dominantnih klasa, dok umeren jednostruki rebalans daje dramatično bolji model.

II. TEORIJSKE OSNOVE

A. Konvolucione neuronske mreže

Konvoluciona neuronska mreža (CNN) koristi lokalno povezane, deljene težine u obliku diskretnih konvolucija. Standardni gradivni blok je konvolucija, zatim slojna normalizacija (batch normalization), pa aktivacija ReLU, i konačno *max-pooling*. Ovaj blok istovremeno uči lokalne filtere, stabilizuje raspodelu aktivacija duž *mini-batch* [4], uvodi nelinearnost i prostorno smanjuje reprezentaciju. Nakon više takvih blokova, prostorna dimenzija se svodi globalnim usrednjavanjem (GAP) na vektor, a linearni klasifikacioni sloj mapira taj vektor u vektor izlaznih vrednosti dužine jednake broju klasa.

B. EfficientNet i transfer učenja

EfficientNet familija [2] uvodi kombinovano skaliranje mreže po dubini, širini i rezoluciji ulaza. Bazna varijanta B0 sadrži oko 5,3 miliona parametara i, na ulazu 224x224 sa ImageNet pretreniranjem, postiže top-1 tačnost od oko 77,1 % na ImageNet-u, uz značajno manje računanja od uporedivih ResNet arhitektura. Za naš zadatak koristimo pretrenirane težine i zamenjujemo poslednji linearni sloj (koji originalno mapira u 1000 ImageNet klasa) novim linearnim slojem koji mapira u 41 klasu.

Fino podešavanje se vrši u dve faze. U prvoj fazi „zamrznu” se ekstraktori i trenira samo novi klasifikacioni sloj, sa većim korakom učenja (reda 0,001). U drugoj fazi odmrzne se cela mreža i trenira sa manjim korakom učenja (reda 0,0001), uz kosinusni raspored. Ovakav dvofazni pristup sprečava da veliki gradijenti iz nasumično inicijalizovanog klasifikacionog sloja iskorumpiraju bogate ImageNet karakteristike u prvim iteracijama.

C. Unakrsna entropija sa težinama i label smoothing

Kod višeklasne klasifikacije koristi se soft-max izlaz i standardna unakrsna entropija (engl. *cross-entropy*) kao funkcija gubitka. Za nebalansirane skupove uvode se težine po klasi: svakom uzorku se u gubitku pridruži težina koja zavisi od učestalosti klase kojoj uzorak pripada, tako da retke klase daju veći doprinos.

Standardni izbor je inverzna frekvencija, gde je težina klase obrnuto proporcionalna broju primera te klase. U prisustvu klasa sa jako malim brojem uzoraka ovakva težina

može biti nekoliko stotina puta veća nego kod najveće klase, što na plitkim mrežama efektivno „nadjačava” gradijent koji dolazi iz krupnijih klasa. Blaži izbor, korišćen u v2 konfiguraciji, težina se skalira sa $-0,5$ stepenom broja uzoraka umesto sa punom inverzijom. Na ovoj raspodeli, odnos najveće i najmanje težine smanjuje se sa približno 420 na 20, pa korekcija više ne destabilizuje obučavanje, već deluje kao oblik regularizacije.

Label smoothing [3] menja ciljnu raspodelu tako što od svakog *one-hot* vektora oduzme mali deo (najčešće između 0,05 i 0,10) i taj deo ravnomerno raspodeli na sve klase. Time se sprečava da model preterano ojača izlaznu vrednost tačne klase i unapređuje se kalibracija verovatnoća; u praksi je ovo standardna tehnika za fino podešavanje pretreniranih klasifikatora slika.

D. Rebalans na nivou uzorka


Klasa se može reponderisati i preko *sampler*-a tipa *WeightedRandomSampler*, gde je verovatnoća izbora uzorka srazmerna recipročnoj vrednosti veličine klase kojoj uzorak pripada. Ako se istovremeno primene težine u gubitku i ovakav *sampler*, korekcije se množe: pri punoj inverznoj frekvenciji u oba dobija se ukupno pojačanje reda 500 puta na najređim klasama. Ovaj režim je primarni uzrok slabih v1 rezultata i detaljnije je analiziran u odeljku V.

E. Augmentacija

Kod treniranja od nule na oko 15.400 slika, plitka mreža lako *overfituje*. Kao regularizatore koristimo *RandomResizedCrop* (nasumično isečen podregion sa faktorima površine između 0,6 i 1,0), horizontalno preslikavanje, *ColorJitter* (nasumične male izmene osvetljenja, kontrasta, zasićenja i nijanse) i *RandomErasing* (nasumično brisanje malog pravougaonika sa verovatnoćom 0,25). Za *EfficientNet* augmentacija je namerno blaža, cilj je da distribucija ulaza ostane blizu ImageNet-ove tokom finog podešavanja.

III. SKUP PODATAKA

Korišćen je skup *willowc/minecraft-biomes* sa Kaggle platforme [8]. Ukupno 22.169 RGB slika u JPEG formatu, rezolucije 320x180 piksela, organizovanih u 41 poddirektorijum oblika *biome_<id>*. Klase su izrazito nebalansirane (Sl. 1): tri najveće (*plains* 3.021, *forest* 2.719, *mountains* 2.469) obuhvataju preko 36 % ukupnog skupa, dok osam najmanjih ima manje od 100 slika svaka, a najređa klasa (*snowy_taiga_mountains*) ima samo 7 slika. Naziv klase je izveden iz standardnog *Minecraft* imenskog registra.



Sl. 1. Raspodela broja slika po klasi u početnom skupu (41 klasa, 22.169 slika ukupno). Odnos najveće (*plains*) i najmanje (*snowy_taiga_mountains*) klase je približno 430 prema 1.

Podela: skup je jednom stratifikovano podeljen na 70/15/15 (*train/val/test*) uz fiksiran seed (42) i sačuvan kao *splits/split.csv*. Time je garantovano da je svaka klasa zastupljena u svakom podskupu i da svi eksperimenti dele istu podelu, čime su rezultati direktno uporedivi.

IV. IMPLEMENTACIJA

A. Programski okvir i infrastruktura

Implementacija je u *Python-u* 3.11 sa *PyTorch-om* 2.x [7] i *torchvision*. Kod je organizovan kao *src* paket (*data*, *models*, *train*, *evaluate*, *utils*) i scripts za skripte (*build_split*, *eda*, *train_baseline*, *train_efficientnet*, *evaluate*). Svi *CLI* (engl. *Command List Interfaces*) ulazi prosleđuju *--seed* vrednost svim izvorima nasumičnosti (*torch*, *numpy*, *Python-ov* *random*) i, kada se koristi, *CUDA* deterministic režimu. Trening prioriteto bira *CUDA*, zatim *Apple MPS* i onda *CPU*.

Sav ulaz je normalizovan standardnim *ImageNet* vrednostima za srednju vrednost (0,485; 0,456; 0,406) i standardnu devijaciju (0,229; 0,224; 0,225), što je nužno za pretrenirani *EfficientNet* i bezopasno za *baseline* model.

B. Referentna konvoluciona mreža

Referentni model (*baseline_cnn.py*) sadrži tri konvoluciona bloka (svaki: *Conv*, *BN*, *ReLU*, *MaxPool*) sa 32, 64 i 128 izlaznih kanala, praćena globalnim usrednjavanjem i klasifikacionim slojem (*Dropout* sa verovatnoćom 0,4 zatim linearni sloj). Parametarski skup je oko 0,25 miliona, čime je ovaj model svesno „mali” — da bi poređenje sa *EfficientNet-om* (5,3 miliona parametara) bilo adekvatnije u smislu razlike u induktivnom biasu (pretreniranje), a ne u kapacitetu.

Ulaz se drži u originalnoj rezoluciji 180x320. Treniranje je podešeno na 40 epoha, *AdamW* [5] sa početnim korakom

učenja 0,001, kosinusnim rasporedom, *batch_size* 64, patience 8, unakrsnom entropijom sa koren-inverznim težinama i sa *label smoothing* podešenim na 0,05.

C. EfficientNet-B0

EfficientNet-B0 se učitava sa *ImageNet* težinama (V1) [6]. Iz standardnog klasifikatora zadržava se dropout, a linearni sloj se zamenjuje novim koji mapira u 41 klasu. Ulaz je predimenzionisan na 224x224 (originalni *ImageNet* ulaz za B0), a podešavanja su stavljena na: 3 epohe i korak učenja 0,001. U drugoj fazi, podešavanja su (*full fine-tune*): 12 epoha, korak učenja 0,0001, kosinusni raspored, *batch_size* 32, *label smoothing* 0,10, koren-inverzne težine kao i kod baseline-a.

D. Metrike i evaluacija

Za svaki model biramo *checkpoint* koji ima najveći makro-F1 na validacionom skupu. Na test skupu računaju se makro, mikro i weighted varijanta metrika Precision, Recall i F1, kao i konfuziona matrica normalizovana po istinitoj klasi. Izbor modela vršimo na osnovu makro-F1, sa weighted F1 kao dopunskim signalom. Sve metrike su računate scikit-learn implementacijama sa opcijom *zero_division* = 0.


V. REZULTATI I DISKUSIJA

Objedinjeni test-rezultati dati su u Tabeli. I. Trening krive prikazane su na Sl. 2, a normalizovane konfuzione matrice na Sl. 3 i Sl. 4.

TABELA. I

Rezime metrika na test skupu (3.326 slika); P = Precision, R = Recall.

Konfig.	Arhitektura	P (mak.)	R (mak.)	F1 makro	F1 weigh.
v1 - baseline	3-conv CNN	0,267	0,469	0,191	0,082
v1 - efficientnet	EfficientNet-B0	0,528	0,664	0,481	0,336
v2 - baseline	3-conv CNN	0,436	0,387	0,370	0,624
v2 - efficientnet	EfficientNet-B0	0,715	0,708	0,704	0,799



Sl. 2. Trening i validacione krive za obe arhitekture u v2 konfiguraciji. Vertikalna isprekidana linija na desnom grafu razdvaja head-only fazu od potpunog finog podešavanja.

A. Problem dvostruke rekalkibracije (v1)

U v1 konfiguraciji istovremeno je aktiviran *WeightedRandomSampler* sa punim inverznim težinama na nivou uzorka i unakrsna entropija sa punim inverznim težinama na nivou klase. Efektivna korekcija je proizvod dva

faktora, sa pojačanjem reda 500 puta u odnosu na najveću klasu. Empirijska posledica na baseline-u:

- Weighted F1 (0,082) je znatno niži od makro F1 (0,191). Weighted F1 je veći ili jednak makrou F1 kod nebalansiranih problema, jer su dominantne klase najlakše.
- Deset najvećih test klasa (*plains* 452, *forest* 409, *mountains* 370, *taiga* 240, *desert* 230, ..., *taiga_hills* 53), ukupno 2.197 od 3.326 slika (oko 66 %), imaju F1 jednako 0,00. Istovremeno klase sa 1 do 5 uzoraka u testu (*snowy_taiga_mountains* 1, *lukewarm_ocean* 2, *tall_birch_hills* 3, *taiga_mountains* 5) imaju recall od 1,0.
- Trening kriva pokazuje jak overfit (*train_loss* 0,48 naspram *val_loss* 3,4 posle 30 epoha), te možemo zaključiti da je augmentacija preblaga za mrežu koja ima oko 15.400 primera za 41 klasu.

Na EfficientNet-u iste tri patologije se pojavljuju blaže, jer *ImageNet* reprezentacije poseduju dovoljno opšte znanje da model prepozna glavne klase, ali ih klasifikacioni gubitak i dalje „kažnjava” i predviđa retke klase. F1 za *plains* pada na 0,013, za *forest* na 0,019, dok *recall* na retkim klasama dostiže 1,0.

B. v2 konfiguracija: umereno rebalansiranje


U v2 je *sampler* isključen, a težine gubitka umerene koren-inverzijom, uz *label smoothing* i (samo za baseline) jaču augmentaciju. Rezultat:

- Baseline dobija 54,3% weighted F1 (sa 0,082 na 0,624) i 17,9% makro F1 (sa 0,191 na 0,370), bez ijedne izmene arhitekture.
- EfficientNet dobija 46,3% weighted F1 (sa 0,336 na 0,799) i 22,3 procentnih poena makro F1 (sa 0,481 na 0,704).
- Weighted F1 je veći ili jednak makro F1 kod oba modela što je i očekivano poređenje.
- Kod baseline-a, 9 od 10 najvećih klasa se ponovo mogu pronaći (*plains* F1 0,86; *savanna* 0,90; *taiga* 0,74; *forest* 0,73; *mountains* 0,72, ...), dok jedina koja ostaje slaba (*wooded_hills*, F1 0,02) trpi zbog blagog mešanja sa *forest* i *mountains*.
- Kod EfficientNet-a je makro-precision približno jednak makro-recall-u (0,715 naspram 0,708), što ukazuje da model nije *biased* ni ka retkim (v1) ni ka dominantnim klasama (nedovoljno kalibrisan baseline bez težina). Za većinu klasa sa 5 ili manje uzoraka, F1 je između 0,43 i 0,86; samo klasa sa jednim test uzorkom (*snowy_taiga_mountains*) ostaje na F1 = 0.


C. Konfuzione matrice

Na Sl. 3 (baseline v2) dijagonala je izražena za količinski dominantne klase (*plains*, *mountains*, *savanna*, *swamp*, *taiga*, *desert*), uz očekivane greške između semantički bliskih parova (*forest* i *wooded_hills*; *desert*, *desert_hills* i *desert_lakes*). Kod EfficientNet-a (Sl. 4) dijagonala je znatno

„toplija” u celom opsegu, uključujući *fine-grained* parove kao što su *birch_forest* i *birch_forest_hills*, ili *giant_tree_taiga* i *giant_tree_taiga_hills*, gde transfer učenja donosi merljiv dobitak.



Sl. 3. Konfuziona matrica (normalizovana po istinitoj klasi) za baseline u v2 konfiguraciji.



Sl. 4. Konfuziona matrica (normalizovana po istinitoj klasi) za EfficientNet-B0 u v2 konfiguraciji.

D. Diskusija

Glavni empirijski nalaz je da konfiguracija gubitka i *sampler*-a u ovom problemu utiče bar koliko i sam izbor arhitekture. Između v1 i v2 nije menjano ništa u arhitekturama; poboljšanja od 56% na baseline-u i 43% na EfficientNet-u dolaze isključivo od tri promene: (i) jedan izvor rebalansa umesto dva; (ii) umerena koren-inverzna korekcija umesto pune inverzije; (iii) label smoothing. Pored toga, jača augmentacija je bila kritična za baseline (uklonila je overfit oko sedam puta) ali ne i za EfficientNet, gde bi jaka

augmentacija udaljila distribuciju od ImageNet-ove i degradirala efekat transfer učenja.

Ograničenja rada: (a) klase sa jednocifrenom test-podrškom su statistički nepouzdanе - $F1 = 0$ na jednom uzorku ne mora biti sistemска greška; (b) *fine-grained* parovi (biome i njegova hills varijanta) ostaju najveći izvor grešaka i verovatno bi imali koristi od većeg ulaza ili karakteristika više razmere.

VI. ZAKLJUČAK

Predstavljena je ponovljiv *pipeline* za klasifikaciju 41 Minecraft bioma iz ekranskih snimaka rezolucije 320x180. Referentna CNN mreža sa tri konvoluciona sloja postiže weighted F1 od 0,62 (makro F1 0,37), dok fino podešeni EfficientNet-B0 postiže weighted F1 od 0,80 (makro F1 0,70). Uočeno je da je pristup rebalansiranju ključan: dvostruko rebalansiranje sa punom inverznom frekvencijom (v1) uništava dominantne klase, dok umeren jednostruki rebalans (v2) daje modele koji su i tačni na količinski dominantnim klasama i degradiraju na retcima. Moguća unapređenja rada su (i) test-vremenska augmentacija i (ii) veći backbone (EfficientNet-B3 ili B4) sa istom v2 procedurom.

REFERENCE

- [1] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, „Gradient-based learning applied to document recognition,” Proc. IEEE, vol. 86, no. 11, pp. 2278-2324, 1998.
- [2] M. Tan and Q. V. Le, „EfficientNet: Rethinking model scaling for convolutional neural networks,” in Proc. ICML, 2019.
- [3] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, „Rethinking the inception architecture for computer vision,” in Proc. IEEE CVPR, 2016.
- [4] S. Ioffe and C. Szegedy, „Batch normalization: Accelerating deep network training by reducing internal covariate shift,” in Proc. ICML, 2015.
- [5] I. Loshchilov and F. Hutter, „Decoupled weight decay regularization,” in Proc. ICLR, 2019.
- [6] O. Russakovsky et al., „ImageNet large scale visual recognition challenge,” Int. J. Computer Vision, vol. 115, pp. 211-252, 2015.
- [7] A. Paszke et al., „PyTorch: An imperative style, high-performance deep learning library,” in Advances in Neural Information Processing Systems, vol. 32, 2019.
- [8] willowc, „Minecraft Biomes dataset,” Kaggle, 2023. [Online]. Dostupno: <https://www.kaggle.com/datasets/willowc/minecraft-biomes/data>